

Informe de laboratorio: selección de la dimensión latente de un autoencoder variacional

Nombre: Eduardo Pivaral Leal

Carné: 20032276

Sección: A?

Fecha de entrega: September 12, 2026

1 Objetivo del laboratorio

Se desea seleccionar un autoencoder variacional capaz de reconstruir dígitos reconocibles, generar muestras plausibles a partir de la distribución normal estándar, producir interpolaciones graduales y mantener una representación compacta. Se comparan las dimensiones latentes

$$d_z \in \{2, 8, 16, 64\}.$$

La recomendación final debe apoyarse en evidencia cuantitativa y cualitativa. Ninguna métrica individual es suficiente para decidir.

2 Hipótesis iniciales

Complete esta sección antes de examinar los resultados.

Pregunta 1

¿Qué dimensión latente espera que produzca la menor pérdida de reconstrucción? Explique la relación esperada entre capacidad latente y reconstrucción.

Respuesta

Se esperaría que $d_z = 64$ tenga la menor pérdida de reconstrucción porque un espacio latente de mayor dimensión tiene mayor capacidad para conservar información de la entrada.

Pregunta 2

¿Qué dimensión espera que produzca las muestras más plausibles para $\mathbf{z} \sim \mathcal{N}(0, I)$? Explique por qué la calidad de muestreo puede no seguir el mismo comportamiento que la reconstrucción.

Respuesta

Se espera que una dimensión intermedia, como $d_z = 16$, produzca las muestras más realistas. Una dimensión mayor puede mejorar la reconstrucción, pero no necesariamente el muestreo, porque el espacio latente puede quedar menos organizado.

Pregunta 3

Prediga si todas las dimensiones disponibles estarán activas en el modelo con $d_z = 64$. ¿Qué significa que una dimensión se encuentre inactiva?

Respuesta

No, probablemente no todas las 64 dimensiones estén activas. Una dimensión inactiva significa que el modelo prácticamente no la usa para guardar información de la imagen, por lo que el decodificador la ignora.

Pregunta 4

Escriba una recomendación inicial. Indique qué evidencia podría hacerle cambiar esa recomendación.

Respuesta

Recomendaría ($d_z = 16$), porque ofrece un buen balance entre reconstrucción, generación y costo. Cambiaría la recomendación si otra dimensión logra resultados similares o mejores.

3 Integridad experimental**Pregunta 5**

Registre la configuración y explique por qué deben mantenerse constantes todos los parámetros distintos de la dimensión latente.

Configuración	Valor
Conjunto de datos	MNIST
Dimensiones latentes	2, 8, 16, 64
β	1
Épocas	8
Tamaño de lote	256
Tasa de aprendizaje	0.001
Semilla aleatoria	42
Umbral de actividad	0.01
Dispositivo utilizado	CPU

Respuesta

Se mantienen todos los parámetros iguales y solo cambia la dimensión latente. Esto permite comparar los modelos de forma justa y asegurar que las diferencias en los resultados se deben a la dimensión latente y no a otros cambios durante la corrida.

4 Resultados cuantitativos

Latent dim	Parameters	Test negative ELBO	Test reconstruction	Test KL	Active dimensions	Active fraction	Training seconds
2	88645	159.342	153.772	5.570	2	1.000	284.881
8	145105	115.518	99.339	16.178	8	1.000	283.950
16	220385	105.613	80.834	24.779	16	1.000	399.093
64	672065	104.853	75.783	29.070	42	0.656	824.937

Table 1: Comparación final de las dimensiones latentes candidatas.

Pregunta 6

Ordene los cuatro modelos según su pérdida de reconstrucción en prueba. ¿Las mejoras entre dimensiones consecutivas son sustanciales o marginales? Incluya los valores medidos.

Respuesta

El orden es: $d_z = 2$ (153.772), $d_z = 8$ (99.339), $d_z = 16$ (80.834) y $d_z = 64$ (75.783). Las mejoras son grandes hasta $d_z = 16$, pero de 16 a 64 la mejora es pequeña, por lo que aumentar tanto la dimension ya no aporta mucho.

Pregunta 7

¿Cómo cambian la divergencia KL total, el número de dimensiones activas y la fracción activa al aumentar d_z ? Explique qué revela cada medida sobre la capacidad latente efectiva.

Respuesta

El KL total aumenta con d_z (5.570, 16.178, 24.779 y 29.070), pero cada vez menos. Las dimensiones activas aumentan de 2 a 8, 16 y 42. Hasta $d_z = 16$ se usa el 100% de las dimensiones, pero con $d_z = 64$ solo se usa el 65.6%.

Pregunta 8

Compare el número de parámetros y el tiempo de entrenamiento. ¿Aumentar d_z modifica sustancialmente el tamaño total y el costo computacional del modelo?

Respuesta

Los parametros aumentan de 88,645 con $d_z = 2$ a 672,065 con $d_z = 64$. El tiempo tambien aumenta de 284.9 s a 824.9 s. Por lo tanto, aumentar d_z incrementa bastante el tamano y costo del modelo, pero la mejora en reconstruccion no aumenta igualmente.

5 Comportamiento durante el entrenamiento




Figure 1: Comportamiento de entrenamiento y prueba para cada dimensión latente.

Pregunta 9

¿Todos los modelos alcanzaron una región razonablemente estable en la última época? Identifique cualquier comparación afectada por convergencia incompleta.

Respuesta

Los cuatro modelos se estabilizan bastante hacia la época 8. Los modelos con $d_z = 8, 16$ y 64 parecen haber convergido bien. El modelo con $d_z = 2$ todavía muestra una menor mejora, por lo que podría obtener mejores resultados con más épocas de entrenamiento.

Pregunta 10

Describe la relación entre la pérdida de reconstrucción, la divergencia KL y el ELBO negativo. ¿Qué término explica las principales diferencias entre modelos?

Respuesta

El ELBO negativo combina la pérdida de reconstrucción y el KL. Al aumentar d_z , la reconstrucción mejora y su pérdida baja, mientras que el KL aumenta. La reconstrucción es la que explica la mayor parte de las diferencias entre los modelos, ya que cambia más que el KL.

6 Análisis de reconstrucción




Figure 2: Reconstrucciones de las mismas imágenes de prueba mediante las medias posteriores.

Pregunta 11

Identifique al menos dos imágenes en las que aumentar d_z produzca una mejora visual significativa. Describa cambios en trazos, forma, ambigüedad o detalles.

Respuesta

Los dígitos 9 y 4 muestran mejoras claras al aumentar d_z . Con $d_z = 2$ se ven borrosos y poco definidos, mientras que con $d_z = 16$ y $d_z = 64$ los trazos son más claros y la forma del dígito se reconoce mejor. con $d_z = 16$ se ven bastante bien claros, excepto el número que creo que es 5 u 8 mal hecho.

Pregunta 12

¿A partir de qué dimensión las dimensiones adicionales muestran rendimientos decrecientes? Utilice evidencia visual y la pérdida de reconstrucción.

Respuesta

Los rendimientos decrecientes aparecen a partir de $d_z = 16$. De $d_z = 16$ a $d_z = 64$ la pérdida solo mejora de 80.83 a 75.78, cerca de un 6%. Visualmente, ambos modelos producen reconstrucciones muy parecidas, por lo que aumentar más la dimensión aporta poca mejora.

7 Análisis de muestras del prior




Figure 3: Muestras generadas a partir de $\mathbf{z} \sim \mathcal{N}(0, I)$.

Pregunta 13

Compare el realismo y la diversidad de las muestras. ¿Qué modelo produce la mayor proporción de dígitos reconocibles? ¿Cuál muestra mayor variedad visible?

Respuesta

Los modelos con $d_z = 8$ y $d_z = 16$ producen la mayor cantidad de dígitos reconocibles y con buena calidad. El modelo con $d_z = 64$ muestra mayor variedad, pero también genera algunos dígitos más feos o irreconocibles. En general, $d_z = 16$ ofrece el mejor resultado costo/claridad.

Pregunta 14

¿El modelo con la mejor reconstrucción también produce las mejores muestras del prior? Explique por qué ambos resultados pueden diferir en un VAE.

Evidencia que debe incluir

Considere el término de reconstrucción y la necesidad de que los posteriores codificados sean compatibles con el prior utilizado para generar.

Respuesta

No necesariamente. $d_z = 64$ tiene la mejor reconstrucción (75.78), pero $d_z = 8$ y $d_z = 16$ producen muestras igual o más reconocibles. Esto ocurre porque reconstruir bien una imagen no significa que el espacio latente esté bien organizado para generar nuevas muestras desde el prior $N(0, I)$.

8 Análisis de interpolación




Figure 4: Interpolación lineal entre las medias posteriores del par seleccionado.

Pregunta 15

¿Qué modelo produce la transición más gradual y plausible? Describa dónde cambia la identidad y si los trazos intermedios permanecen coherentes.

Respuesta

El modelo con $d_z = 16$ produce la transición mas gradual y clara. El dígito 3 se mantiene reconocible hasta cerca de $t = 0.5$ y luego cambia poco a poco hasta formar un 8. Los trazos intermedios se mantienen bastante coherentes durante la transición.

Pregunta 16

¿Una interpolación suave demuestra que cada dimensión latente tiene un significado interpretable? Explique la limitación de esa conclusión.

Respuesta

No. Una interpolación suave solo indica que el modelo puede pasar gradualmente entre dos puntos del espacio latente. No significa que cada dimensión tenga un significado específico, ya que una dimensión puede representar varios atributos al mismo tiempo.

9 Organización del espacio latente




Figure 5: Medias posteriores: representación directa para $d_z = 2$ y PCA para espacios mayores.

Pregunta 17

¿Qué clases forman regiones distinguibles? Identifique clases que se superponen y explique si su similitud visual puede justificarlo.

Respuesta

Las clases 0, 1 y 7 forman regiones bastante distinguibles. En cambio, 3, 4, 5, 6, 8 y 9 se superponen mas. Esto es razonable porque varios de estos digitos tienen trazos y formas similares, especialmente en un espacio de solo $d_z = 2$.

Pregunta 18

¿Por qué la gráfica directa de $d_z = 2$ debe interpretarse de manera diferente a las proyecciones bidimensionales obtenidas mediante PCA?

Respuesta

Con $d_z = 2$ se muestra directamente todo el espacio latente, sin perder información. En dimensiones mayores se usa PCA para reducirlas a 2 dimensiones, por lo que se pierde parte de la información. Por eso, dos clases que parecen mezcladas en PCA pueden estar separadas en el espacio latente original.


10 Análisis de dimensiones activas

Figure 6: Contribución KL promedio de cada dimensión; la línea discontinua indica el umbral de actividad.

Pregunta 19

¿Cada modelo utiliza todas las dimensiones disponibles? Compare el número y la proporción de dimensiones activas.

Respuesta

No. Los modelos con $d_z = 2$, $d_z = 8$ y $d_z = 16$ usan el 100% de sus dimensiones. En cambio, $d_z = 64$ solo usa 65.6%. Esto indica que el modelo de 64 tiene mas capacidad de la que realmente necesita.

Pregunta 20

Si el modelo de 64 dimensiones deja muchas dimensiones inactivas, ¿qué implica para su capacidad nominal y efectiva? ¿Debe considerarse automáticamente un fracaso de entrenamiento?

Respuesta

No significa que el entrenamiento haya fallado, sino que el modelo no necesita usar toda la capacidad disponible. Sería un fallo si se determina que el costo o el tiempo es demasiado alto para el ejercicio que se use, pero en este lab no es problema.

11 Recomendación final**Pregunta 21: dimensión seleccionada**

Recomiendo $d_z = 16$ para el escenario planteado.

Pregunta 22: justificación basada en evidencia

Defienda su decisión utilizando:

- al menos tres valores cuantitativos;
- evidencia de reconstrucción;
- realismo y diversidad de las muestras del prior;
- comportamiento de las interpolaciones;
- dimensiones latentes activas; y
- compacidad o costo computacional.

Respuesta

$d_z = 16$ ofrece el mejor balance entre calidad y costo. Logra una reconstrucción de 80.83, cercana a 75.78 de $d_z = 64$, pero usa muchos menos parámetros (220,385 vs. 672,065) y menos de la mitad del tiempo de entrenamiento (399.1 s vs. 824.9 s). Además, genera buenos dígitos, interpolaciones coherentes y utiliza el 100% de sus dimensiones. Por eso, aumentar a $d_z = 64$ agrega mucho costo para una mejora pequeña.

Pregunta 23: debilidad del modelo seleccionado

Identifique la principal debilidad del modelo recomendado. Explique por qué la recomendación sigue siendo razonable.

Respuesta

La principal debilidad de $d_z = 16$ es que su reconstrucción (80.83) es un poco peor que la de $d_z = 64$ (75.78), por lo que puede perder algunos detalles finos. Aun así, la diferencia es menor frente al ahorro en parámetros y tiempo de entrenamiento.

Pregunta 24: escenario alternativo

Describa un uso realista en el que otra dimensión sería preferible. Seleccione la dimensión alternativa y justifique su elección.

Respuesta

En un sistema donde la calidad de reconstrucción sea la prioridad, usaría $d_z = 64$, ya que tiene la menor pérdida de reconstrucción (75.78). Aunque requiere más recursos, el costo adicional es aceptable si no existen restricciones de tiempo o hardware.

12 Limitaciones y experimentos posteriores**Pregunta 25**

Identifique al menos tres limitaciones del experimento. Considere duración del entrenamiento, variación aleatoria, subjetividad visual, complejidad de MNIST, arquitectura y umbral de actividad.

Respuesta

1. Solo se probaron cuatro dimensiones latentes (2, 8, 16, 64). Probar valores como 24 o 32 podría encontrar un mejor punto entre calidad y costo.
2. Se utilizó una sola arquitectura de VAE. Una arquitectura diferente podría cambiar el rendimiento y hacer que otra dimensión latente sea más conveniente.
3. Solo se utilizó $\beta = 1$. Cambiar este valor puede modificar el balance entre reconstrucción y regularización KL, y por lo tanto cambiar cuál dimensión latente funciona mejor.

Pregunta 26

Proponga un experimento posterior que fortalezca la recomendación. Indique la variable que cambiaría, las cantidades que mediría y qué resultado apoyaría o contradiría su decisión.

Respuesta

Probaría nuevas dimensiones latentes, por ejemplo $d_z = 12, 24$ y 32 , manteniendo iguales los demás parámetros. Mediría la pérdida de reconstrucción, el ELBO, el tiempo de entrenamiento y la cantidad de dimensiones activas. Si una dimensión intermedia como $d_z = 24$ logra una calidad similar a $d_z = 64$ con menor costo, cambiaría la recomendación. Si $d_z = 16$ sigue siendo el mejor balance entre calidad y eficiencia, mantendría la decisión actual.

13 Conclusión

Escriba una conclusión de 150–250 palabras. Indique el modelo seleccionado, resuma la evidencia decisiva y describa el principal compromiso observado.

Respuesta

Los resultados muestran que aumentar la dimensión latente mejora la reconstrucción, pero el beneficio se reduce conforme aumenta d_z . El cambio más importante se observa en las dimensiones pequeñas, mientras que pasar de $d_z = 16$ a $d_z = 64$ reduce la pérdida de reconstrucción solamente de 80.83 a 75.78.

Existe entonces un compromiso entre aprovechar una mayor capacidad y mantener un modelo eficiente. Aunque $d_z = 64$ consigue la menor pérdida, requiere 672,065 parámetros y 824.94

segundos de entrenamiento. Además, solo 42 de sus 64 dimensiones permanecen activas. En comparación, $d_z = 16$ utiliza sus 16 dimensiones, necesita 220,385 parámetros y completa el entrenamiento en 399.1 segundos.

La evaluación visual también favorece a $d_z = 16$: las reconstrucciones conservan bien la forma de los dígitos, las muestras generadas son reconocibles y las interpolaciones presentan cambios graduales y coherentes.

Por lo tanto, para este experimento seleccionaría $d_z = 16$. Los resultados sugieren que esta dimensión ya proporciona suficiente capacidad para representar MNIST, mientras que agregar muchas más dimensiones aumenta considerablemente el costo del modelo sin producir una mejora equivalente en los resultados.

Lista de verificación

- ☐ Se respondieron las 26 preguntas.
- ☐ La recomendación final selecciona una dimensión latente.
- ☐ Las afirmaciones cuantitativas incluyen valores medidos.
- ☐ Las afirmaciones cualitativas hacen referencia a figuras o ejemplos.
- ☐ Se diferencia la gráfica directa de las proyecciones mediante PCA.
- ☐ Se analiza una limitación y un escenario alternativo.
- ☐ El informe completo compila sin errores.