

Reporte de laboratorio: clasificación tabular con MLP

Nombre:Eduardo Pivaral 20032276

Fecha: 16 de agosto de 2026

Archivo entregado: laboratorio_estudiante_20032276.ipynb

Propósito. Se comparó un MLP convencional con un MLP residual con Batch Normalization para clasificar datos tabulares. La selección se realizó únicamente con el conjunto de desarrollo, manteniendo el conjunto privado fuera de este proceso.

1. Datos, división y control de fuga

Elemento	Valor	Evidencia o justificación	Estado
Archivo público	train_1000_desbalanceado.csv	1,000 ejemplos	Usado
División	800 train / 200 dev	Estratificada, semilla 17	Usado
Clases en train	600 clase 0 / 200 clase 1	Proporción positiva: 0.25	Verificado
Estandarización	Media y desviación de train	Ajustada sólo con x_{train}	Sin fuga
Test privado	No usado durante selección	Reservado para evaluación final	No usado

Control de fuga. Una fuente de fuga sería calcular la media y la desviación estándar usando los 1,000 ejemplos antes de dividir los datos. Eso permitiría que la información del conjunto de desarrollo influyera en el entrenamiento. Se evitó ajustando el estandarizador solamente con `x[indice_train]` y aplicando después esos mismos parámetros a train y dev.

2. Estrategia ante el desbalance

Decisión	Valor elegido	Justificación
Pérdida	BCE ponderada; peso positivo = 3,0	Se calcula como 600/200. Cada positivo recibe peso 3 para compensar que hay tres negativos por cada positivo.
Selección de modelo	Costo esperado en dev	Se usó costo de falso negativo = 10 y falso positivo = 1. No detectar un positivo se considera diez veces más grave.
Métricas reportadas	Accuracy, precision, recall, F1 y especificidad	Accuracy sola puede ser alta al acertar mayormente negativos, aunque se fallen positivos.
Umbral	Seleccionado sólo en dev	Se congela el umbral antes de cualquier evaluación privada.


El umbral 0.5 no tiene por qué ser óptimo: supone implícitamente una decisión simétrica. Como el falso negativo es más costoso, se eligió el umbral que minimiza $10 FN + 1 FP$ en desarrollo.

3. Búsqueda de hiperparámetros

ID	Arquitectura	Capas/ancho	LR	Épocas	Costo dev	F1	Recall	Umbral
A	MLP	[32, 16]	0.002	120	39	0.887	0.940	0.39
B	Residual + BN	32	0.002	120	60	0.857	0.900	0.10


Decisión. Se eligió el modelo A (MLP) porque obtuvo el menor costo operacional en desarrollo: 39 frente a 60. La regla de desempate definida sería mayor F1 y, si persistiera el empate, mayor recall. El notebook ejecutado contiene dos configuraciones; por ello se reportan sólo esas dos y no se inventan resultados adicionales.

4. Curvas de entrenamiento y desarrollo



La pérdida de entrenamiento disminuyó de 0.614 a 0.114. La pérdida de desarrollo alcanzó su mínimo de 0.178 en la época 64 y terminó en 0.199. Esto sugiere un sobreajuste leve después de aproximadamente la época 64. El modelo guardado corresponde al entrenamiento de 120 épocas, pues el procedimiento del notebook no guarda checkpoints intermedios.

5. Selección de umbral y reporte de métricas



Conjunto	Accuracy	Precision	Recall	F1	Especificidad
Desarrollo, umbral 0.39	0.940	0.839	0.940	0.887	0.940
Test privado, umbral congelado	No evaluado	No evaluado	No evaluado	No evaluado	No evaluado

Matriz de confusión en desarrollo.

	Pred. 0	Pred. 1
Real 0	141	9
Real 1	3	47

Con el umbral 0.39 se obtuvieron $TP = 47$, $FP = 9$, $FN = 3$ y $TN = 141$; por tanto, el costo es $10(3) + 1(9) = 39$.

6. Conclusión reproducible

1. Arquitectura final: MLP con capas ocultas [32, 16], entrenado por 120 épocas con tasa de aprendizaje 0.002 y peso positivo 3.0. Artefacto: `entrega/modelo_elegido.npz`.
2. Umbral congelado: 0.39. Costos asumidos: falso negativo 10 y falso positivo 1.
3. Antes de desplegar, evaluaría una búsqueda con más configuraciones y aplicaría el modelo una sola vez al test privado o a nuevos datos representativos.